Сборник задач по курсу "Машинное обучение"

авторы: Кантонистова Е.О., Титов В.В., Широков А., Поликарпов К. $15~{\rm октябрs}~2020~{\rm r}.$

Содержание

1	Матричное дифференцирование			
	1.1	Теория	4	
	1.2	Семинар	4	
	1.3	Домашнее задание	4	
2	Линейные классификаторы часть 1			
	2.1	Семинар	4	
	2.2	Домашнее задание	4	
3	Линейные классификаторы часть 2			
	3.1	Семинар	(
	3.2	Домашнее задание	7	

1 Матричное дифференцирование

1.1 Теория

Иногда при взятии производных по вектору или от вектор-функций удобно оперировать матричными операциями. Это сокращает запись и упрощает вывод формул. Введём следующие определения:

- При отображении вектора в число $f(x): \mathbb{R}^n \to \mathbb{R}$ $\nabla_x f(x) = [\frac{\partial f}{\partial x_1},...,\frac{\partial f}{\partial x_n}]^T.$
- При отображении матрицы в число $f(A): \mathbb{R}^{n \times m} \to \mathbb{R}$ $\nabla_A f(A) = (\frac{\partial f}{\partial A_{ij}})_{i,j=1}^{n,m}.$

Мы хотим оценить, как функция изменяется по каждому из аргументов по отдельности. Поэтому производной функции по вектору будет вектор, по матрице — матрица.

Полезные свойства:

- 1) $d(XY) = dX \cdot Y + X \cdot dY$
- 2) Если A матрица константа, то dA=0
- 3) d(X') = dX'
- 4) $d \det X = \det X tr(X^{-1} dX)'$

1.2 Семинар

Задача 1.1. Пусть $a \in \mathbb{R}^n$ — вектор параметров, а $x \in \mathbb{R}^n$ — вектор переменных. Необходимо найти производную их скалярного произведения по вектору переменных $\nabla_x a^T x$.

Задача 1.2. Пусть $A \in \mathbb{R}^{n \times n}$. Необходимо найти $\nabla_A det A$.

Задача 1.3. Пусть $A \in \mathbb{R}^{n \times n}$, $B \in \mathbb{R}^{n \times n}$. Необходимо найти $\nabla_A tr(AB)$.

Задача 1.4. Пусть $x \in \mathbb{R}^n$, $A \in \mathbb{R}^{n \times m}$, $y \in \mathbb{R}^m$. Необходимо найти $\nabla_A x^T A y$.

1.3 Домашнее задание

Задача 1.5. Пусть t — скалярная переменная, r, s — векторные переменные, R, S — матричные переменные. Кроме того, a, b — векторы констант, A, B — матрицы констант. Применив базовые правила дифференцирования найдите:

- 1. d(ARB)
- 2. d(r'r)

3. d(r'Ar)4. $d(R^{-1})$, воспользовавшись тем, что $R^{-1}R=I$ 5. $d(\cos(r'r))$ 6. d(r'Ar/r'r)

Задача 1.6. Пусть $A \in \mathbb{R}^{n \times n}$. Необходимо найти $\nabla_x x^T A x$

2 Линейные классификаторы часть 1

2.1 Семинар

Задача 2.1. Линейный классификатор выдал следующие значения для объектов из набора данных: $b_i = \mathbb{P}(y_i = 1|x_i)$.

Уі	\mathbf{b}_i
1	0.7
-1	0.2
-1	0.3
-1	0.8
1	0.6

Необходимо:

- 1. Построить ROC-кривую
- 2. Найти площадь под ROC-кривой и индекс Джини
- 3. Построить PR-кривую (кривая точность-полнота)
- 4. Найти площадь под PR-кривой

Задача 2.2. Дан алгоритм классификации, который выдаёт вероятность принадлежности объекта к положительному классу $b_i = \mathbb{P}(y_i = 1|x_i)$. Также есть набор данных с объектами двух типов: 100 китов и 900 муравьев. В качестве признака алгоритм использует количество глаз у объекта (у китов и муравьёв 2 глаза). После применения алгоритма к набору данных для каждого объекта было получено число $b_i = f(x_i) \in [0; 1]$, оценка вероятности того, что наблюдение является китом.

Решите задачу минимизации эмпирической функции риска и найдите все b_i для функций потерь:

- 1. $L(y_i, b_i) = (y_i b_i)^2$, если для муравьёв $y_i = 0$;
- 2. $L(y_i, b_i) = |y_i b_i|$, если для муравьёв $y_i = 0$;

2.2 Домашнее задание

Задача 2.4. Рассмотрим плоскость в \mathbb{R}^3 , задаваемую уравнением $5x_1+6x_2-7x_3+10=0$ и две точки, A=(2,1,4) и B=(4,0,4).

- 1. Найдите любой вектор, перпендикулярный плоскости;
- 2. Правда ли, что отрезок AB пересекает плоскость?
- 3. Найдите длину отрезка AB;
- 4. Не находя расстояние от точек до плоскости, определите, во сколько раз точка A дальше от плоскости, чем точка B;

5. Найдите расстояние от точки A до плоскости.

Задача 2.5. Закончите предложения:

- 1. accuracy это доля правильных ответов. . .
- 2. точность (precision) это доля правильных ответов. . .
- 3. полнота (recall) это доля правильных ответов. . .
- 4. TPR это доля правильных ответов. . .

Задача 2.6. Алгоритм бинарной классификации выдаёт оценки вероятности $b_i = \mathbb{P}(y_i = 1|x_i)$. Всего проведено 10000 наблюдений. Если ранжировать их по возрастанию b_i , то окажется что наблюдения с $y_i = 1$ занимают ровно места с 5501 по 5600. Найдите площадь по ROC-кривой и площадь под PR-кривой.

Задача 2.7. Для условия задачи 2.2. минимизируйте эмпирическую функцию риска и найдите все b_i для функций потерь:

1.
$$L(y_i, b_i) = \begin{cases} -\log b_i, \text{ если } y_i = 1 \\ -\log (1 - b_i), \text{ иначе} \end{cases}$$
;

2.
$$L(y_i,b_i) = \begin{cases} 1/\mathbf{b}_i, \text{ если } y_i = 1 \\ 1/(1-\mathbf{b}_i), \text{ иначе} \end{cases}$$
;

3 Линейные классификаторы часть 2

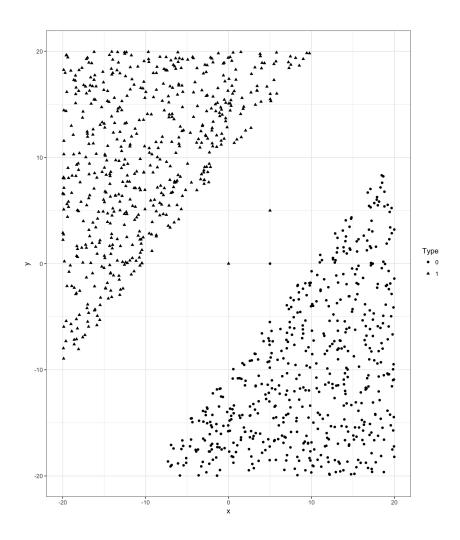
3.1 Семинар

Задача 3.1. Построить персептон, реализующий логическое ИЛИ.

Задача 3.2. На плоскости имеются точки двух цветов. Красные: (1,1),(1,-1) и синие: (-1,1),(-1,-1).

- 1. Найдите разделяющую полосу методом опорных векторов при разных C;
- 2. Укажите опорные вектора.

Задача 3.3. По картинке качественно решите задачу разделения точек:



Целевая функция имеет вид:

$$\min_{w,w_0} \frac{1}{2}w'w + C\sum_{i=1}^n \epsilon_i$$

Уравнение разделяющей поверхности: $w'x = w_0$, уравнения краёв полосы: $w'x = w_0 + 1$ и $w'x = w_0 - 1$. Нарушителями считаются наблюдения, которые попали на нейтральную полосу или на чужую территорию. Здесь $\epsilon_i = |w| \cdot d_i$, где d_i - заступ наблюдения за черту.

- 1. Как пройдёт разделяющая полоса при C=1? Найдите w,w_0 , величины штрафов ϵ_i .
- 2. Как пройдёт разделяющая полоса при $C = +\infty$? Найдите w, w_0 , величины штрафов ϵ_i .

Задача 3.4. Дана таблица сопряженности x и y:

Будем использовать логистическую регрессию с константой для прогнозирования y с помощью x.

- 1. Какие оценки коэффициентов мы получим?
- 2. Какой прогноз вероятности y=1 при значении признака x=0 даёт логистическая модель? Как это число можно посчитать без рассчитывания коэффициентов?

Задача 3.5. Показать, что из формулы логистической регрессии

$$p(y = +1|x) = \frac{1}{1 + e^{-w^T x}}$$

следует, что (w, x) - это логарифм отношения шансов (log-odds).

Задача 3.6. Показать, что квадратичная функция потерь

$$L(y,z) = ([y=+1]-z)^2$$

позволяет предсказывать корректные вероятности.

3.2 Домашнее задание

Задача 3.7. Построить персептон, реализующий логическое НЕ.

Задача 3.8.* Построить двухслойный персептон, реализующий ХОР.

Задача 3.9. На плоскости имеются точки двух цветов. Красные: $(1,1),\ (1,-1)$ и синие: $(-1,1),\ (-1,-1)$ и (2,0).

- 1. Найдите разделяющую гиперплоскость методом опорных векторов при разных C.
- 2. Укажите опорные вектора.

Задача 3.10. Покажите, что абсолютная функция потерь

$$L(y,z) = |[y = +1] - z|, z \in [0;1]$$

не позволяет предсказывать корректные вероятности.

Задача 3.11. Рассмотрим целевую функцию логистической регрессии с константой

$$Q(w) = \frac{1}{l} \sum_{i=1}^{n} L(y_i, b_i),$$

где
$$b_i=1$$
 / $(1+exp(-\langle w,x_i\rangle))$ и $L(y_i,b_i)=egin{cases} -log\ b_i,\ \text{если}\ y_i=1\\ -log(1-b_i),\ \text{иначе} \end{cases}$

Найдите градиент Q(w).

Задача 3.12. Оценка логистической модели для прогнозирования y_i , в зависимости от x_i и z_i : $\ln odds_i=2+0.3x_i-0.5z_i$. Оцените вероятность того, что $y_i=1$ для x=15, z=3.5.