

# Сборник задач по курсу "Машинное обучение"

авторы: Кантонистова Е.О., Титов В.В., Широков А., Поликарпов К.

26 ноября 2020 г.

## Содержание

<b>1</b>	<b>Матричное дифференцирование</b>	<b>2</b>
1.1	Теория . . . . .	2
1.2	Семинар . . . . .	2
1.3	Домашнее задание . . . . .	2
<b>2</b>	<b>Линейные классификаторы часть 1</b>	<b>4</b>
2.1	Семинар . . . . .	4
2.2	Домашнее задание . . . . .	4
<b>3</b>	<b>Линейные классификаторы часть 2</b>	<b>6</b>
3.1	Семинар . . . . .	6
3.2	Домашнее задание . . . . .	7
<b>4</b>	<b>Ядра</b>	<b>9</b>
4.1	Семинар . . . . .	9
4.2	Домашнее задание . . . . .	9
<b>5</b>	<b>Снижение размерности</b>	<b>11</b>
5.1	Семинар . . . . .	11
5.2	Домашнее задание . . . . .	11
<b>6</b>	<b>Решающие деревья</b>	<b>13</b>
6.1	Семинар . . . . .	13
<b>7</b>	<b>Бэггинг и бустинг</b>	<b>14</b>
7.1	Семинар . . . . .	14
7.2	Домашнее задание . . . . .	15

# 1 Матричное дифференцирование

## 1.1 Теория

Иногда при взятии производных по вектору или от вектор-функций удобно оперировать матричными операциями. Это сокращает запись и упрощает вывод формул. Введём следующие определения:

- При отображении вектора в число  $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$   
 $\nabla_x f(x) = [\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n}]^T$ .
- При отображении матрицы в число  $f(A) : \mathbb{R}^{n \times m} \rightarrow \mathbb{R}$   
 $\nabla_A f(A) = (\frac{\partial f}{\partial A_{ij}})_{i,j=1}^{n,m}$ .

Мы хотим оценить, как функция изменяется по каждому из аргументов по отдельности. Поэтому производной функции по вектору будет вектор, по матрице — матрица.

Полезные свойства:

- 1)  $d(XY) = dX \cdot Y + X \cdot dY$
- 2) Если  $A$  - матрица константа, то  $dA = 0$
- 3)  $d(X') = dX'$
- 4)  $d \det X = \det X \operatorname{tr}(X^{-1}dX)'$

## 1.2 Семинар

**Задача 1.1.** Пусть  $a \in \mathbb{R}^n$  – вектор параметров, а  $x \in \mathbb{R}^n$  – вектор переменных. Необходимо найти производную их скалярного произведения по вектору переменных  $\nabla_x a^T x$ .

**Задача 1.2.** Пусть  $A \in \mathbb{R}^{n \times n}$ . Необходимо найти  $\nabla_A \det A$ .

**Задача 1.3.** Пусть  $A \in \mathbb{R}^{n \times n}$ ,  $B \in \mathbb{R}^{n \times n}$ . Необходимо найти  $\nabla_A \operatorname{tr}(AB)$ .

**Задача 1.4.** Пусть  $x \in \mathbb{R}^n$ ,  $A \in \mathbb{R}^{n \times m}$ ,  $y \in \mathbb{R}^m$ . Необходимо найти  $\nabla_A x^T A y$ .

## 1.3 Домашнее задание

**Задача 1.5.** Пусть  $t$  – скалярная переменная,  $r$ ,  $s$  – векторные переменные,  $R$ ,  $S$  – матричные переменные. Кроме того,  $a$ ,  $b$  – векторы констант,  $A$ ,  $B$  – матрицы констант. Применив базовые правила дифференцирования найдите:

1.  $d(ARB)$
2.  $d(r'r)$

3.  $d(r'Ar)$
4.  $d(R^{-1})$ , воспользовавшись тем, что  $R^{-1}R = I$
5.  $d(\cos(r'r))$
6.  $d(r'Ar/r'r)$

**Задача 1.6.** Пусть  $A \in \mathbb{R}^{n \times n}$ . Необходимо найти  $\nabla_x x^T Ax$

## 2 Линейные классификаторы часть 1

### 2.1 Семинар

**Задача 2.1.** Линейный классификатор выдал следующие значения для объектов из набора данных:  $b_i = \mathbb{P}(y_i = 1|x_i)$ .

$y_i$	$b_i$
1	0.7
-1	0.2
-1	0.3
-1	0.8
1	0.6

Необходимо:

1. Построить ROC-кривую
2. Найти площадь под ROC-кривой и индекс Джини
3. Построить PR-кривую (кривая точность-полнота)
4. Найти площадь под PR-кривой

**Задача 2.2.** Дан алгоритм классификации, который выдаёт вероятность принадлежности объекта к положительному классу  $b_i = \mathbb{P}(y_i = 1|x_i)$ . Также есть набор данных с объектами двух типов: 100 китов и 900 муравьёв. В качестве признака алгоритм использует количество глаз у объекта (у китов и муравьёв 2 глаза). После применения алгоритма к набору данных для каждого объекта было получено число  $b_i = f(x_i) \in [0; 1]$ , оценка вероятности того, что наблюдение является китом.

Решите задачу минимизации эмпирической функции риска и найдите все  $b_i$  для функций потерь:

1.  $L(y_i, b_i) = (y_i - b_i)^2$ , если для муравьёв  $y_i = 0$ ;
2.  $L(y_i, b_i) = |y_i - b_i|$ , если для муравьёв  $y_i = 0$ ;

### 2.2 Домашнее задание

**Задача 2.4.** Рассмотрим плоскость в  $\mathbb{R}^3$ , задаваемую уравнением  $5x_1 + 6x_2 - 7x_3 + 10 = 0$  и две точки,  $A = (2, 1, 4)$  и  $B = (4, 0, 4)$ .

1. Найдите любой вектор, перпендикулярный плоскости;
2. Правда ли, что отрезок  $AB$  пересекает плоскость?
3. Найдите длину отрезка  $AB$ ;
4. Не находя расстояние от точек до плоскости, определите, во сколько раз точка  $A$  дальше от плоскости, чем точка  $B$ ;

5. Найдите расстояние от точки  $A$  до плоскости.

**Задача 2.5.** Закончите предложения:

1. ассигасу — это доля правильных ответов. . .
2. точность (precision) — это доля правильных ответов. . .
3. полнота (recall) — это доля правильных ответов. . .
4. TPR — это доля правильных ответов. . .

**Задача 2.6.** Алгоритм бинарной классификации выдаёт оценки вероятности  $b_i = \mathbb{P}(y_i = 1|x_i)$ . Всего проведено 10000 наблюдений. Если ранжировать их по возрастанию  $b_i$ , то окажется что наблюдения с  $y_i = 1$  занимают ровно места с 5501 по 5600. Найдите площадь по ROC-кривой и площадь под PR-кривой.

**Задача 2.7.** Для условия задачи 2.2. минимизируйте эмпирическую функцию риска и найдите все  $b_i$  для функций потерь:

$$1. L(y_i, b_i) = \begin{cases} -\log b_i, & \text{если } y_i = 1 \\ -\log (1 - b_i), & \text{иначе} \end{cases} ;$$

$$2. L(y_i, b_i) = \begin{cases} 1/b_i, & \text{если } y_i = 1 \\ 1/(1 - b_i), & \text{иначе} \end{cases} ;$$

## 3 Линейные классификаторы часть 2


### 3.1 Семинар

**Задача 3.1.** Построить перцептон, реализующий логическое ИЛИ.

**Задача 3.2.** На плоскости имеются точки двух цветов. Красные:  $(1, 1)$ ,  $(1, -1)$  и синие:  $(-1, 1)$ ,  $(-1, -1)$ .

1. Найдите разделяющую полосу методом опорных векторов при разных  $C$ ;
2. Укажите опорные вектора.

**Задача 3.3.** По картинке качественно решите задачу разделения точек:



Целевая функция имеет вид:

$$\min_{w, w_0} \frac{1}{2} w' w + C \sum_{i=1}^n \epsilon_i$$

Уравнение разделяющей поверхности:  $w'x = w_0$ , уравнения краёв полосы:  $w'x = w_0 + 1$  и  $w'x = w_0 - 1$ . Нарушителями считаются наблюдения, которые попали на нейтральную полосу или на чужую территорию. Здесь  $\epsilon_i = |w| \cdot d_i$ , где  $d_i$  - заступ наблюдения за черту.

1. Как пройдёт разделяющая полоса при  $C = 1$ ? Найдите  $w, w_0$ , величины штрафов  $\epsilon_i$ .
2. Как пройдёт разделяющая полоса при  $C = +\infty$ ? Найдите  $w, w_0$ , величины штрафов  $\epsilon_i$ .

**Задача 3.4.** Дана таблица сопряженности  $x$  и  $y$ :

	$y_i = 1$	$y_i = 0$
$x_i = 1$	12	36
$x_i = 0$	32	20

Будем использовать логистическую регрессию с константой для прогнозирования  $y$  с помощью  $x$ .

1. Какие оценки коэффициентов мы получим?
2. Какой прогноз вероятности  $y = 1$  при значении признака  $x = 0$  даёт логистическая модель? Как это число можно посчитать без рассчитывания коэффициентов?

**Задача 3.5.** Показать, что из формулы логистической регрессии

$$p(y = +1|x) = \frac{1}{1 + e^{-w^T x}}$$

следует, что  $(w, x)$  - это логарифм отношения шансов (log-odds).

**Задача 3.6.** Показать, что квадратичная функция потерь

$$L(y, z) = ([y = +1] - z)^2$$

позволяет предсказывать корректные вероятности.

## 3.2 Домашнее задание

**Задача 3.7.** Построить перцептон, реализующий логическое ИЕ.

**Задача 3.8.\*** Построить двухслойный перцептон, реализующий XOR.

**Задача 3.9.** На плоскости имеются точки двух цветов. Красные:  $(1, 1)$ ,  $(1, -1)$  и синие:  $(-1, 1)$ ,  $(-1, -1)$  и  $(2, 0)$ .

1. Найдите разделяющую гиперплоскость методом опорных векторов при разных  $C$ .
2. Укажите опорные вектора.

**Задача 3.10.** Покажите, что абсолютная функция потерь

$$L(y, z) = |[y = +1] - z|, \quad z \in [0; 1]$$

не позволяет предсказывать корректные вероятности.

**Задача 3.11.** Рассмотрим целевую функцию логистической регрессии с константой

$$Q(w) = \frac{1}{l} \sum_{i=1}^n L(y_i, b_i),$$

где  $b_i = 1 / (1 + \exp(-\langle w, x_i \rangle))$  и  $L(y_i, b_i) = \begin{cases} -\log b_i, & \text{если } y_i = 1 \\ -\log(1 - b_i), & \text{иначе} \end{cases}$

Найдите градиент  $Q(w)$ .

**Задача 3.12.** Оценка логистической модели для прогнозирования  $y_i$ , в зависимости от  $x_i$  и  $z_i$ :  $\ln \text{odds}_i = 2 + 0.3x_i - 0.5z_i$ . Оцените вероятность того, что  $y_i = 1$  для  $x = 15, z = 3.5$ .



## 4 Ядра

### 4.1 Семинар

**Задание 4.1.** Переход из двумерного пространства в расширяющее задан функцией

$$f : (x_1, x_2) \longrightarrow (1, x_1, x_2, 3x_1x_2, 2x_1^2, 4x_2^2).$$

Найдите соответствующую ядерную функцию.

**Задание 4.2.** Ядерная функция имеет вид

$$K(x, y) = x_1^2 y_1^2 + x_2^2 y_2^2 + 2x_1 x_2 y_1 y_2.$$

Как может выглядеть функция  $f : R^2 \longrightarrow R^3$  переводящие исходные векторы в расширенное пространство?

**Задание 4.3.** Является ли функция  $K(x, z) = \begin{cases} 1 & \text{if } x = z \\ 0 & \text{otherwise} \end{cases}$  ядром?

**Задание 4.4.** Докажите, что произведение ядер является ядром.

**Задание 4.5.** Докажите, что RBF-ядро это ядро.

### 4.2 Домашнее задание

**Задание 4.6.** Ядерная функция, скалярное произведение в расширяющем пространстве, имеет вид  $K(a, b) = \exp(-|a - b|^2)$ . Имеются вектора  $a = (1, 1, 1)$  и  $b = (1, 2, 0)$ .

Найдите длину векторов и косинус угла между ними в исходном и расширяющем (спрямляющем) пространстве.

**Задание 4.7.** Рассмотрим два вектора,  $v_1 = (1, 1, 2)$  и  $v_2 = (1, 1, 1)$ . Переход в спрямляющее пространство осуществляется с помощью гауссовской ядерной функции с параметром  $\gamma$ ,  $k(v, v') = \exp(-\gamma|v - v'|^2)$ .

1. Как от  $\gamma$  зависят длины векторов в спрямляющем пространстве?
2. Как от  $\gamma$  зависит угол между векторами в спрямляющем пространстве?

**Задание 4.8.** Имеются три наблюдения  $A$ ,  $B$  и  $C$ :

	$x$	$y$
$A$	1	-2
$B$	2	1
$C$	3	0

1. Найдите расстояние  $AB$  и косинус угла  $ABC$ .
2. Найдите расстояние  $AB$  и косинус угла  $ABC$  в расширенном пространстве с помощью гауссовского ядра с  $K(x, x') = \exp(-|x - x'|^2)$ .
3. Найдите расстояние  $AB$  и косинус угла  $ABC$  в расширенном пространстве с помощью полиномиального ядра второй степени.

**Задание 4.9.** Является ли функция  $K(x, z)$  ядром?

1.  $K(x, z) = \begin{cases} 0 & \text{if } x = z \\ 1 & \text{otherwise} \end{cases};$
2.  $K(x, z) = \cos(x^T x) \sin(z^T z);$
3.  $K(x, z) = \sin(x^T z);$

## 5 Снижение размерности

### 5.1 Семинар

**Задание 5.1.** Найдите SVD-разложение матриц.

1.  $X = \begin{pmatrix} 0 & -7 \\ 0 & 0 \\ 0 & 0 \end{pmatrix}$

2.  $X = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$

**Задание 5.2.** Дано сингулярное разложение матрицы  $X$

$$X = U \cdot \begin{pmatrix} 7 & 0 & 0 \\ 0 & 3 & 0 \end{pmatrix} \cdot V'$$

Если возможно найдите сингулярное разложение для

1.  $X', 10X$ ;
2.  $X'X, XX'$ ;

**Задание 5.3.** Найдите прямую, у которой сумма квадратов расстояний до точек  $(0, 0)$ ,  $(1, 1)$ ,  $(2, 1)$  будет минимальной. Чему равна при этом доля объяснённого разброса точек?

**Задание 5.4.** Есть две переменных,  $x = (1, 0, 0, 3)'$ ,  $z = (3, 2, 0, 3)'$ . Найдите первую и вторую главные компоненты (то есть, собственные векторы матрицы  $X^T X$ ).

### 5.2 Домашнее задание

**Задание 5.5.** Найдите SVD-разложение матриц.

1.  $X = \begin{pmatrix} 3 \\ 4 \end{pmatrix}$

2.  $X = \begin{pmatrix} 1 & 1 \\ 2 & 2 \\ 2 & 2 \end{pmatrix}$

3.  $X = \begin{pmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{pmatrix}$

**Задание 5.6.** Дано сингулярное разложение матрицы  $X$

$$X = U \cdot \begin{pmatrix} 7 & 0 & 0 \\ 0 & 3 & 0 \end{pmatrix} \cdot V'$$

Если возможно, найдите сингулярное разложение для

1.  $(X'X)^4, (XX')^{-1}, 5I + X'X$ ;
2.  $X'(XX')^{-1}X$ ;
3.  $X(X'X)^{-1}X'$ ;

**Задание 5.7.** Известна матрица выборочных ковариаций трёх переменных. Для удобства будем считать, что переменные уже центрированы.

$$\begin{pmatrix} 11 & 2 & -8 \\ 2 & 2 & 10 \\ -8 & 10 & 5 \end{pmatrix}$$

Найдите первую и вторую главные компоненты. Какую долю дисперсии они объясняют?

## 6 Решающие деревья

### 6.1 Семинар

**Задание 6.1.** Постройте регрессионное дерево для прогнозирования  $y$  с помощью  $x$  на обучающей выборке:

$x_i$	0	1	2	3
$y_i$	5	6	4	100

Критерий деления узла на два — минимизация RSS. Дерево строится до трёх терминальных узлов.

**Задание 6.2.** В мешке находятся 20 белых шаров, 40 черных, 2 красных и 8 синих. Как изменился индекс Джини и энтропия после того, как все черные шары перенесли в новый мешок?

**Задание 6.3.** Приведите примеры наборов данных, для которых индекс Джини равен 0, 0.5 и 0.999.

## 7 Бэггинг и бустинг


### 7.1 Семинар

**Задание 7.1.** В мешке есть 100 разных шаров. Равновероятно вытаскиваем из мешка по одному шару и кладем его обратно. Сколько в среднем шаров оказываются невытащенными ни разу за 100 таких действий.

**Задание 7.2.** Есть выборка из четырёх наблюдений:

$x_i$	1	2	3	4
$y_i$	6	6	12	18

Есть два дерева:



Используем бэггинг. Первому дереву достались наблюдения номер 1, 1, 2 и 3. А второму дереву — 2, 3, 4 и 4. Прогнозы в каждом листе строятся минимизируя сумму квадратов ошибок. Какие прогнозы внутри обучающей выборки мы получим с помощью такого леса?

**Задание 7.3.** Истинная зависимость имеет вид  $y_i = x_i^2 + u_i$ , где  $y_i$  - прогнозируемая переменная,  $x_i$  - предиктор и  $u_i$  - ненаблюдаемая случайная составляющая. Величины  $x_i$  независимы и равновероятно принимают значения 1 и 2. Величины  $u_i$  независимы и равновероятно принимают значения -1 и 1. Обучающая выборка состоит из двух наблюдений.


Разложите ожидание квадрата ошибки прогноза на шум, смещение и разброс, если:

1. Вне зависимости от обучающей выборки из-за ошибки в коде в качестве прогноза всегда выдаётся 0.
2. в качестве прогноза алгоритм всегда выдает последний  $y$  из обучающей выборки.

**Задание 7.4.** Есть выборка из четырёх наблюдений:

$x_i$	1	2	3	4
$y_i$	6	6	12	18

Есть два дерева:



Используем бустинг с темпом обучения  $\nu$ . Прогнозы в каждом листе конкретного дерева строим минимизируя функцию:

$$Q = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^T w_j^2$$

где  $y_i$  — прогнозируемое значение для  $i$ -го наблюдения,  $n$  — количество наблюдений,  $w_j$  — прогноз в  $j$ -ом листе,  $T$  — количество листов на дереве. Какие прогнозы внутри обучающей выборки получатся при  $\nu = 1$  и  $\lambda = 1$ ?

## 7.2 Домашнее задание

**Задание 7.5.** Постройте регрессионное дерево для прогнозирования  $y$  с помощью  $x$  на обучающей выборке:

$y_i$	$x_i$
100	1
102	2
103	3
50	4
55	5
61	6
70	7

Критерий деления узла на два — минимизация RSS. Узлы делятся до тех пор, пока в узле остаётся больше двух наблюдений.

**Задание 7.6.** Есть выборка из пяти наблюдений:

$y_i$	$x_i$
1	10
2	11
2	12
3	13
3	14

Постройте классификационное дерево для прогнозирования  $y_i$  с помощью  $x_i$  на обучающей выборке. Дерево строится до идеальной классификации. Критерий деления узла на два — максимальное падение индекса Джини.

**Задание 7.7.** Построим классификационное дерево для бинарной переменной  $y_i$ . Может ли при разбиении узла на два расти индекс Джини? Энтропия?

**Задание 7.8.** Рассмотрим задачу построения классификационного дерева для бинарной переменной  $y_i$ . Приведите пример такого набора данных, что никакое разбиение стартового узла на два не снижает индекс Джини, однако двух разбиений достаточно, чтобы снизить индекс Джини до нуля.

**Задание 7.9.** Постройте классификационное дерево для прогнозирования  $y$  с помощью  $x$  и  $z$  на обучающей выборке:

$x_i$	0	0	0	1	1
$z_i$	1	2	3	3	5
$y_i$	0	1	1	0	0


Критерий деления узла на два — минимизация индекса Джини. Дерево строится до идеальной классификации.

**Задание 7.10.** Есть выборка из четырёх наблюдений:

$x_i$	1	2	3	4
$y_i$	6	6	12	18

Есть два дерева:





Используем бэггинг. Первому дереву достались наблюдения номер 1, 1, 2 и 3. А второму дереву — 2, 3, 4 и 4. Прогнозы в каждом листе конкретного дерева строим минимизируя функцию:

$$Q = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^T w_j^2$$

Какие прогнозы внутри обучающей выборки мы получим с помощью такого леса?

**Задание 7.11.** Истинная зависимость имеет вид  $y_i = 3x_i^2 + u_i$ , где  $y_i$  - прогнозируемая переменная,  $x_i$  - предиктор и  $u_i$  - ненаблюдаемая случайная составляющая. Величины  $x_i$  независимы и равновероятно принимают значения 0, 1, 2. Величины  $u_i$  независимы и равновероятно принимают значения -1 и 1.

Оценим модель линейной регрессии  $y_i = \hat{\beta}x_i$  с помощью МНК. Разложите ожидание квадрата ошибки прогноза на шум, смещение и разброс.